

Translacja z Pythona – dokumentacja wstępna

Autor: Jakub Ficek

Temat projektu

Celem projektu jest stworzenie translatora skrótnego dla wybranego podzbioru języka Python do języka C++. Program będzie napisany w języku Python3.

Założenia

- Obsługiwanymi typami są int, float, bool
- Wszystkie zmienne są statycznie typowane (zmienna nie może być najpierw typu int a potem float)
- Obsługa własnych funkcji z adnotowanymi typami argumentów i zwracanej wartości
- Obsługa instrukcji warunkowych if elif else
- Obsługa pętli while
- Obsługa wyrażeń matematycznych i logicznych
- Obsługa wyjścia przy pomocy funkcji print

Przykłady

```
x = 5
while x > 0:
    if x % 3 == 0:
        print(0)
    elif x % 3 == 1:
        print(1)
    else:
        print(2)
    x = x - 1
```

```
#include <iostream>

using namespace std;

int main()
{
    int x;
    x = 5;
    while(x > 0)
    {
        if(x % 3 == 0)
        {
            cout << 0 << endl;
        }
        else if(x % 3 == 1)
        {
            cout << 1 << endl;
        }
        else
        {
            cout << 2 << endl;
        }
        x = x - 1;
    }
    return 0;
}
```

```
def sum(a: int, b: int) -> int:
    return a + b

x = 2

while x > 0 and 1 == 1:
    x = x - 1
    print(x)
y = 3 + 2 * 2
print(sum(x, y))
```

```
#include <iostream>

using namespace std;

int sum(int a, int b)
{
    return a + b;
}

int main()
{
    int x;
    int y;
    x = 2;
    while(x > 0 && 1 == 1)
    {
        x = x - 1;
        cout << x << endl;
    }
    y = 3 + 2 * 2;
    cout << sum(x, y) << endl;
    return 0;
}
```

```
x=2
x++
```

error: line 2

Lista zdefiniowanych tokenów

- 'def' - DEF,
- 'if' - IF,
- 'elif' - ELIF,
- 'else' - ELSE,
- 'while' - WHILE,
- 'None' - NONE,
- 'int' - INT,
- 'float' - FLOAT,
- 'bool' - BOOL,
- 'return' - RETURN,
- 'print' - PRINT,
- ':' - COLON,
- ',' - COMMA,
- '->' - RETURN_TYPE,
- '\+' - PLUS,
- '-' - MINUS,
- '*' - MULTIPLY,
- '/' - DIVIDE,
- '(' - LP,
- '\)' - RP,
- '%' - MODULO,
- '==' - ISEQUAL,

'!=' - ISNOTEQUAL,
 '<=' - ISEQUALLESS,
 '<' - ISLESS,
 '>=' - ISEQUALLESS,
 '>' - ISMORE,
 '=' - EQUALS,
 'and' - AND,
 'or' - OR,
 'not' - NOT,
 '\d+\.\d+' - VALUE_FLOAT,
 '\d+' - VALUE_INT,
 'True|False' - VALUE_BOOL,
 '[a-zA-Z_][a-zA-Z0-9_]*' - IDENTIFIER
 wzrost liczby tabulacji w nowej linii – INDENT
 zmniejszenie liczby tabulacji w nowej linii – DEDENT
 taka sama liczba tabulacji w nowej linii – NEWLINE

Gramatyka

program = statements

statements = statement | statement statements

statement = assignment_statement | function_statement | return_statement | while_statement | if_statement | print_statement | expression_statement | NEWLINE | INDENT | DEDENT

assignment_statement = IDENTIFIER ISEQUAL expression_statement

function_statement = DEF IDENTIFIER LP [IDENTIFIER COLON type] { COMMA IDENTIFIER' COLON type } RP RETURN_TYPE (type | NONE) COLON INDENT

return_statement = RETURN expression_statement

while_statement = WHILE expression_statement COLON INDENT

if_statement = IF expression_statement COLON INDENT [el_statement]

el_statement = else_statement | elif_statement

elif_statement = ELIF expression_statement COLON INDENT [el_statement]

else_statement = ELSE COLON INDENT statement_block

print_statement = PRINT LP [expression_statement] {COMMA expression_statement } RP

expression_statement = func_call | operation

operation = { unary_op | unary_logic_op } expression_statement { binary_op | binary_logic_op | comparison_op expression_statement }

func_call = IDENTIFIER LP [identifier | value] { COMMA (identifier | value) } RP

unary_op = PLUS | MINUS

unary_logic_op = NOT

binary_op = PLUS | MINUS | MULTIPLY | DIVIDE | MODULO

binary_logic_op = AND | OR

comparison_op = ISEQUAL | ISNOTEQUAL | ISLESS | ISEQUALLESS | ISMORE | ISEQUALMORE

type = INT | FLOAT | BOOL

value = VALUE_INT | VALUE_FLOAT | VALUE_BOOL

Sposób uruchomienia

Program z kodem napisanym w języku Python, jako wyjście program wypisuje lub tworzy plik z analogicznym kodem napisanym w C++ albo wypisuje komunikat o odpowiednim błędzie (błąd może wystąpić na etapie analizy leksykalnej lub składniowej)

Moduły

- **Moduł obsługi plików** – odpowiedzialny za wczytywanie tekstu z pliku i tworzenie pliku wyjściowego
- **Lekser** – odpowiedzialny za rozbicie tekstu wczytanego z pliku na tokeny, które trafiają do analizatora składniowego.
- **Parser** – odpowiedzialny za sprawdzenie czy wczytany ciąg tokenów jest zgodny z gramatyką zdefiniowanego podzbioru oraz zbudowanie drzewa rozbioru.
- **Generator kodu** – odpowiedzialny za konstrukcję kolejnych instrukcji w C++, przechodząc drzewo rozbioru oraz korzystając z tablicy symboli, aby zainicjalizować wszystkie zmienne
- **Moduł obsługi błędów** – odbiera błędy z leksera, parsera oraz prezentuje błędy w czytelny sposób (numer linii)

Dodatkowe struktury danych:

- **Tablica symboli** – zawierająca używane w kodzie wejściowym identyfikatory oraz informacje o ich typie i zasięgu, uzupełniana przez parser
- **Tablica akceptowalnych tokenów** – predefiniowana tablica wszystkich zdefiniowanych symboli, używana przez lekser

Reguły translacji

- Stała struktura kodu w C++, pojawiająca się zawsze:

```
#include <iostream>
```

```
using namespace std;
```

```
//definicje funkcji
```

```
int main()
```

```
{
```

```
    // inicjalizacja zmiennych o zasięgu globalnym
```

```
    // translacja pythonowych instrukcji
```

```
    return 0;
}
```

- dla DETEND i NEWLINE dodawany jest średnik i znak nowej linii
- Na początku funkcji inicjowane są wszystkie zmienne lokalne
- Zamiana INT, FLOAT, BOOL, NONE na kolejno 'int', 'float', 'bool', 'void'
- Zamiana funkcji postaci 'def func(arg1: type1, arg2:type2) -> type3:' na 'type3 func(type1 arg1, type2 arg2)'
- INDENT oznaczane przez '{', a DEDENT przez '}'
- Zamiana 'if expression:' na 'if(expression)'
- Zamiana 'elif expression:' na 'else if(expression)'
- Zamiana 'else:' na 'else'
- Zamiana 'while expression:' na 'while(expression)'
- Operatory porównania, przypisania oraz arytmetyczne pozostają bez zmian
- Zamiana operatorów logicznych 'not', 'and', 'or' na kolejno '!', '&&', '||'
- Zamiana 'print(expression1, expression2)' na 'cout << expression1 << expression2 << endl'

Testowanie

Testowanie będzie odbywać się przy użyciu krótkich przykładów testujących, porównując uzyskany przez program kod z oczekiwanym.